

Projet

Traitement de signal biomédical pour la caractérisation de l'encodage mémoirel

2ème année

Groupe 4

-

Tom PELLETREAU-DURIS

Maika TOUZET

Année 2020-2021

Sommaire

Introduction	3
Analyse fréquentielle d'un signal	4
Bruit blanc gaussien centré	4
Bruit blanc de moyenne $=7$ et de variance $2=9$	5
Régularité d'un signal	5
Detrended fluctuation analysis d'ordre 3 (DFA3)	6
Profil du signal	6
Tendances locales	6
Exposant de Hurst	7
Test sur signaux synthétiques de régularité connue	8
Detrending Moving Average (DMA)	8
Caractérisation du filtre	8
Fonction de transfert	9
Phase et module de la fonction de transfert	10
Exposant de Hurst	12
Test sur signaux synthétiques de régularité connue	13
Mise en oeuvre sur des signaux physiologiques	13
Gestion de projet	15
Conclusion	165
Bibliographie	165

Introduction

Le traitement du signal est une discipline fructueuse et particulièrement intéressante lorsque l'on s'intéresse aux ondes et aux informations qu'elles transmettent. Les applications sont nombreuses car concernent aussi bien l'optique et les supports numériques qui l'utilisent, les ondes électromagnétiques et les télécommunications qui résultent de leur étude, que les ondes d'origine biologique recueillies sous forme de signaux biomédicaux. Comprendre une fréquence R-R ou un diagramme temps-fréquence d'un EEG sont le moyen de mesurer et de comprendre les informations qui circulent dans le corps humain comme autant de signatures d'états physiologiques.

Ici, nous nous intéressons plus particulièrement au traitement du signal concernant les processus cognitifs de "charge mentale". On parle aussi de charge cognitive. Le concept de charge mentale est souvent utilisé en sciences cognitives pour aborder la gestion des ressources cognitives par un individu vis à vis d'une situation de stress. En effet, au cours de l'exécution d'une tâche, l'état dans lequel se trouve l'opérateur varie selon son niveau d'aptitude à comprendre et résoudre le problème engendré par la tâche. Cette aptitude varie selon les émotions ressenties par l'opérateur comme l'énervement, la joie, la fatigue, la confiance (Martin, C., Hourlier, S. & Cegarra, J.) et c'est en cela qu'il en découle certaines modifications physiologiques traduisant un certain niveau de stress cognitif. Par là, nous pouvons comprendre que les mesures de ces modifications physiologiques peuvent représenter des marqueurs de l'état cognitif du sujet observé.

Dans l'hypothèse où ces marqueurs seraient bel et bien le reflet de la charge mentale d'un opérateur, il convient d'étudier tout particulièrement les signaux récoltés par électro-encéphalographie. L'étude des phénomènes électro-biologiques porteurs d'informations cérébrales peuvent dire quelque chose de l'intensité de la concentration par exemple. Sans rentrer dans les détails d'une analyse cognitive complète de la charge mentale - cela impliquerait d'exposer ici les modalités complexes qui entrent en compte dans la gestion d'une tâche par un sujet humain - il est fondamental, lorsque l'on s'intéresse à ce sujet vaste, de savoir manipuler le traitement d'un signal de sortie d'un système de mesure EEG (électro-encéphalogramme). C'est pour cela que nous nous proposons ici de mettre en évidence la démarche scientifique, relevant de l'ingénierie cognitive, propre au traitement d'un signal EEG. Car, comment comprendre le sens et la portée qualitative d'une mesure EEG, afin de l'interpréter pertinemment, sans comprendre le fonctionnement propre à cette mesure et le traitement quantitatif des signaux produits ?

Nous nous proposons d'explicitier la méthodologie de l'ingénieur cognitif face à cette problématique avec l'outil de traitement de données Matlab® et son langage de programmation propre. Tout d'abord nous montrerons comment un signal peut être acquis puis analysé dans le domaine temporel et fréquentiel, notamment en liant ces deux repères par l'analyse temps-fréquence. En deuxième lieu nous présenterons la méthode associée à l'analyse de la régularité d'un signal grâce aux méthodes DFA (detrended fluctuations analysis) et DMA (detrended moving average). Dans ces premières parties, nous testerons les méthodes sur des signaux connus (bruits blancs) afin de s'assurer de la fonctionnalité des outils développés. Enfin, nous montrerons comment ces méthodes peuvent s'appliquer à l'analyse d'un signal EEG afin de caractériser la profondeur d'encodage mémoriel d'un utilisateur, c'est à dire, sa capacité à transformer des informations traitées par sa mémoire de travail en informations mémorielles de long terme.

1. Analyse fréquentielle d'un signal

Dans cette partie nous nous intéressons à l'analyse d'un signal dans le domaine temporel et fréquentiel et sous sa représentation de sa fréquence en fonction du temps. Cela permet de visualiser l'évolution de la richesse fréquentielle du signal au cours du temps et nous donne ainsi la possibilité d'identifier des moments clé de changement d'états.

1.1. Bruit blanc gaussien centré

Tout d'abord, il nous faut définir un bruit blanc gaussien de moyenne μ et de variance $V = \sigma^2$, dans notre exemple il est réduit et centré, d'où $\mu = 0$ et $\sigma = 1$. Nous l'étudions sur un échantillon fictif de taille $M = 2001$ avec une fréquence d'échantillonnage $f_e = 1000\text{Hz}$ et nous le générons avec la fonction Matlab `randn(début, fin)` qui génère un vecteur où chaque élément est un nombre aléatoire compris entre $[-1; 1]$. Pour représenter temporellement ce bruit, on peut afficher l'amplitude en fonction du temps (en secondes) ou la fréquence en fonction du temps par un spectrogramme. Le temps physique en secondes est $T_{psP} = T_{psD} \times T_e = \frac{T_{psD}}{f_e}$ avec T_{psD} le temps discret (vecteur de 0 à $M - 1$).

Un spectrogramme étant assimilable à une analyse fréquentielle périodique glissante, il faut définir une taille à la fenêtre d'observation et un taux de recouvrement correspondant au nombre de points qu'ont en commun deux fenêtres consécutives. Notre signal durant 2 secondes et ayant une fréquence d'échantillonnage $f_e = 1000\text{Hz}$, une fenêtre de taille 44 m.s^{-1} où il y a donc, par construction, 44 échantillons par fenêtre correspond à ce qui se fait généralement en traitement du signal : prendre la racine carré du nombre d'échantillon total comme fenêtre $\sqrt{M} \simeq 44,7$. On choisit, comme on le fait généralement, un taux de recouvrement égal à 50% de la fenêtre, il faut ici de $\frac{\sqrt{M}}{2} \simeq 22$.

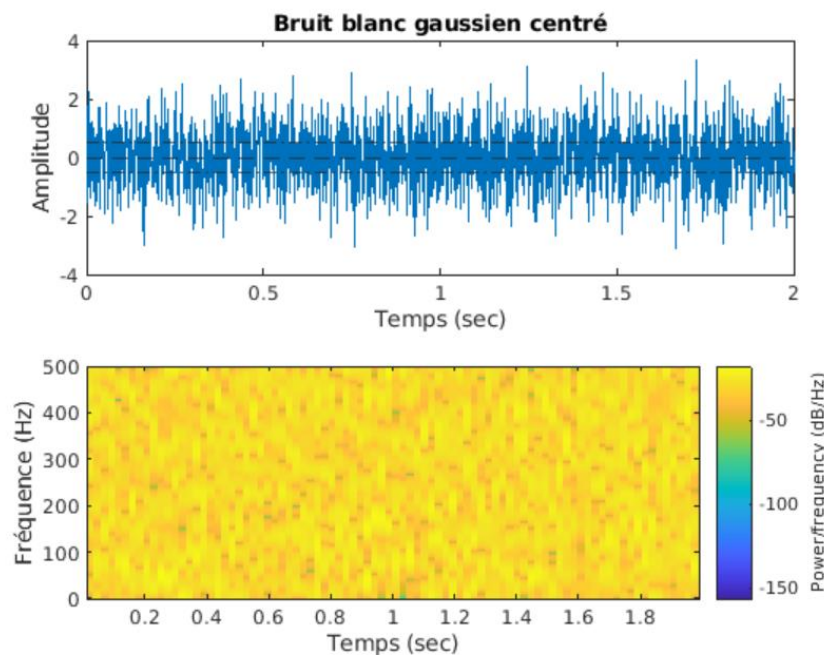


Figure 1 : Représentation graphique et spectrogramme d'un bruit blanc gaussien

Nous observons en **Figure 1** des colonnes de valeurs globalement similaires sans pouvoir dégager de structure identifiable, ce qui est normal car c'est un bruit. La puissance portée par ces signaux est homogène, le signal est bien stationnaire.

1.2. Bruit blanc de moyenne $\mu = 7$ et de variance $\sigma^2 = 9$

Ce deuxième signal étudié est un bruit blanc de moyenne $\mu = 7$ et de variance $\sigma^2 = 9$. Nous l'étudions sur un échantillon de taille $M = 2001$ avec une fréquence d'échantillonnage $f_e = 1000\text{Hz}$. Les paramètres pour la création du spectrogramme ont été choisis de la même façon que pour le bruit blanc gaussien.

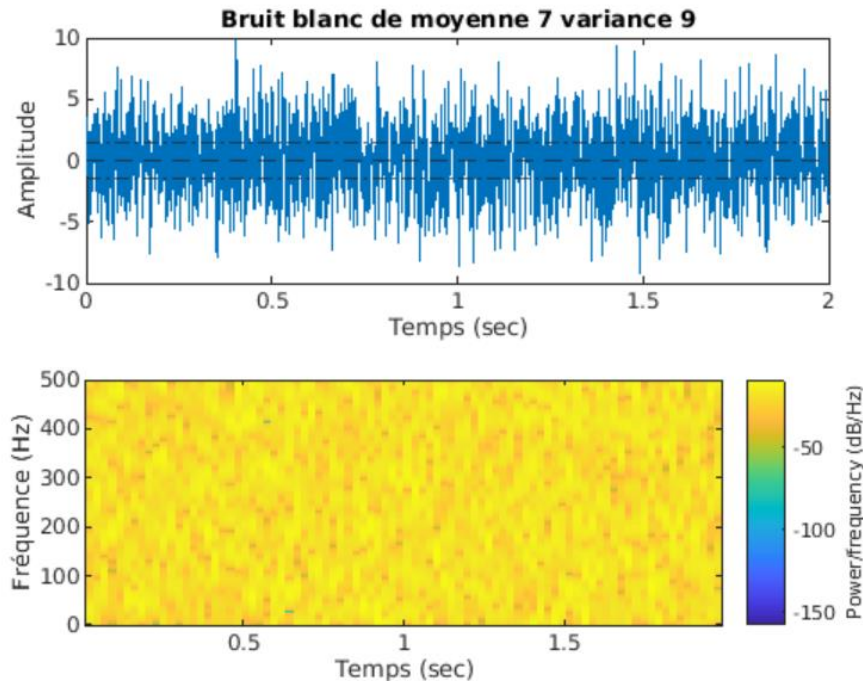


Figure 2 : Représentation graphique et spectrogramme d'un bruit blanc avec $\mu = 7$ et $\sigma^2 = 9$.

Comme pour le signal précédent, la **Figure 2** montre que ce signal est stationnaire puisque les colonnes sont homogènes.

2. Régularité d'un signal

Dans cette partie, nous nous intéressons à des algorithmes de mesure de la régularité d'un signal. La régularité d'un signal est un indice du comportement d'un signal et de son invariance au cours du temps et s'assimile à la mémoire d'un processus. En effet, plus un signal présente des dépendances temporelles sur le long terme, plus il porte en lui le motif d'une structure globale. À l'inverse, plus un point est corrélé avec son voisinage proche plutôt que lointain, moins le signal semble traduire d'une intelligibilité générale. L'enjeu de la méthode DFA est d'étudier un signal sur plusieurs sous parties d'échantillons de taille variable afin d'approximer sa tendance sur ces échantillons. Elle utilise une régression polynomiale d'ordre 3 afin d'assimiler le comportement du signal à une courbe lissée. On détermine ensuite la tendance globale du profil en concaténant les tendances locales obtenus avant de déduire la racine carrée de la puissance des résidus, c'est-à-dire la racine carrée de l'écart, au carré et pondéré, entre le modèle et le signal effectif. Cette racine carrée de la puissance du résidu permettant finalement de mesurer α , l'exposant de Hurst,

qui caractérise la régularité globale du signal. La méthode DMA prend le parti d'approximer la tendance locale de notre signal par un filtrage linéaire plutôt que par une régression polynomiale mais suit la même logique pour finalement trouver α .

2.1. Detrended fluctuation analysis d'ordre 3 (DFA3)

Mettons en place l'algorithme de la méthode DFA 3. Comme expliqué, nous l'appliquons à un bruit blanc gaussien, qui par définition est régulier. Nous devrions donc obtenir un exposant de Hurst $\alpha = 0,5$.

2.1.1. Profil du signal

Tout d'abord nous effectuons une intégration discrète du signal. Pour m allant de 1 à M , le profil est $y_{int}(m) = \sum_{i=1}^m (y(i) - \mu_y)$ avec $\mu_y = \frac{1}{M} \sum_{m=1}^M y(m)$ ce qui correspond à la moyenne temporelle du signal y . Ce profil est tracé en **Figure 3** ci-dessous.

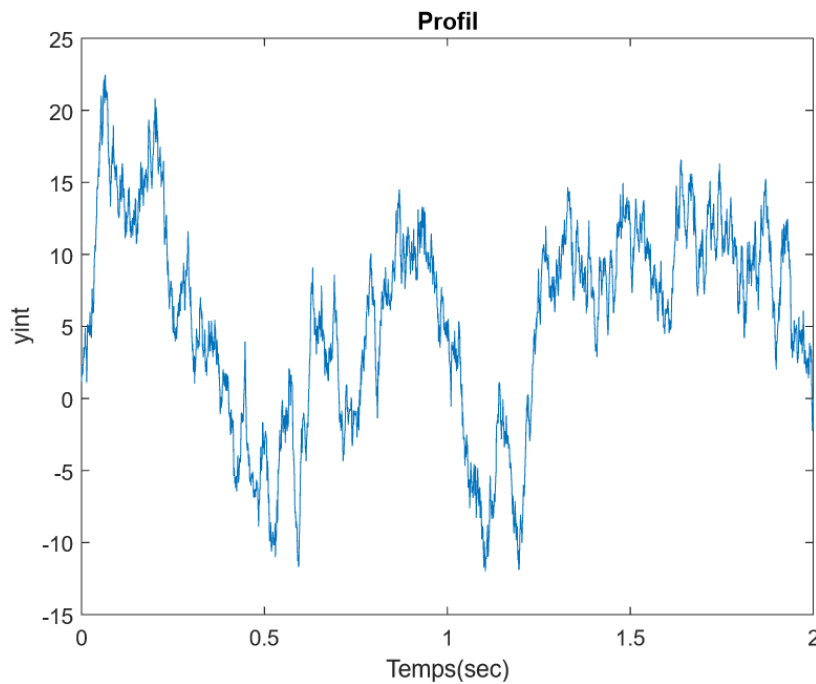


Figure 3 : Profil y_{int}

2.1.2. Tendances locales

Afin de déterminer les tendances locales de notre profil selon plusieurs degrés de finesse, il nous faut choisir différentes tailles à notre fenêtre d'observation. On définit les tailles de segments par le vecteur $N = [13, 17, 21, 27, 35, 47, 59, 77, 99, 135, 189]$. On découpe alors le profil en $L = \frac{M}{n}$ avec $n \in N$ (arrondi à l'entier inférieur) segments. Sur chaque segment l entre 1 et L , nous estimons la tendance locale selon une régression d'ordre 3. En évaluant le $n^{\text{ème}}$ échantillon du $l^{\text{ème}}$ segment, on peut modéliser la tendance locale telle que :

$$x_l(n) = a_{l,3}[(l-1)N + n]^3 + a_{l,2}[(l-1)N + n]^2 + a_{l,1}[(l-1)N + n] + a_{l,0} \text{ où } l \in [1, L] \text{ et } n \in [1, N]$$

On détermine alors les paramètres $a_{l,0}$, $a_{l,1}$, $a_{l,2}$, $a_{l,3}$ en minimisant l'expression suivante :

$$J_{DFA}(a_{l,3}, a_{l,2}, a_{l,1}, a_{l,0}) = \sum_{n=1}^N (y_{int}((l-1)N + n) - x_l(n))^2$$

On obtient alors les tendances locales présentées en **Figure 4** où les segments sont représentés à l'aide de barres verticales.

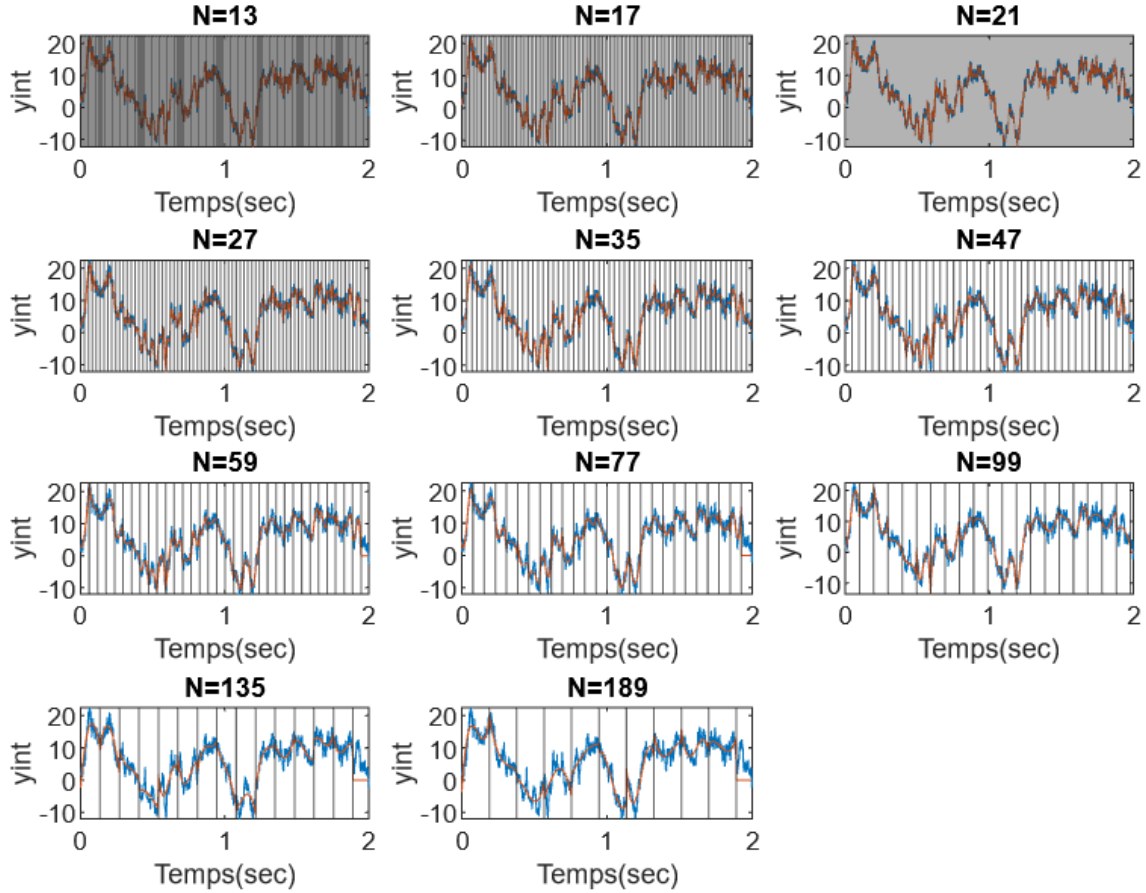


Figure 4 : Le profil y_{int} et ses tendances locales sur les L segments de taille N

Plus N est petit, plus le nombre de segments est grand. Les tendances locales sont donc plus précises.

La tendance globale est la concaténation de toutes ces tendances locales.

2.1.3. Exposant de Hurst

Finalement, la dernière étape consiste à estimer α , l'exposant de Hurst, à partir des différents calculs de tendances locales en fonction des différentes valeurs de N . Avec la racine carré de la puissance du résidu :

$$F(N) = \sqrt{\frac{1}{LN} \sum_{l=1}^L \sum_{n=1}^N (y_{int}((l-1)N + n) - x_l(n))^2}$$

On sait que, $F(n) \propto n^\alpha$ avec α l'exposant de Hurst. On a alors $\log(F(N)) = \alpha \log(N)$.

On peut donc représenter $\log(F(N))$ en fonction de $\log(N)$ (**Figure 5**). En effectuant une régression linéaire, on obtient la valeur de α .




Figure 5 : Pente de la représentation log-log

L'exposant de Hurst caractérise la régularité d'un signal. Pour un signal régulier, on doit obtenir $\alpha = 0,5$. Un bruit blanc est, par définition, régulier.

Ici, on a $\alpha = 0,4884$. Le résultat est donc proche du résultat théorique.

2.1.4. Test sur signaux synthétiques de régularité connue

Afin de vérifier l'exactitude de nos calculs, nous les répétons sur une cinquantaine de bruits blancs gaussiens centrés et une cinquantaine de bruits blancs de moyenne $\mu = 7$ et de variances $\sigma^2 = 9$ en recherchant $\alpha = 0,5$. On obtient alors une moyenne $\underline{\alpha} = 0,5128$ et une variance de $6,6 \cdot 10^{-4}$ pour les bruits blancs gaussiens centrés et une moyenne $\underline{\alpha} = 0,5094$ et une variance de $6,7 \cdot 10^{-4}$ pour les bruits blancs de moyenne non nulle. Dans les deux cas, la variance est très faible et la moyenne est proche de 0,5. Cela nous permet donc de valider le code et d'obtenir des résultats avec une faible variabilité.

2.2. Detrending Moving Average (DMA)

La deuxième méthode à mettre en place est la méthode DMA. Comme précédemment, nous lui appliquons un bruit blanc gaussien. La différence majeure avec la DFA réside dans le filtrage que nous nous proposons d'étudier ci-dessous.

2.2.1. Caractérisation du filtre

On applique un filtre de réponse impulsionnelle $h_{DMA}(n) = \frac{1}{N}$ au signal, pour $n = 0, \dots, N-1$. Puisqu'un filtrage se traduit mathématiquement comme une convolution, le filtrage ici peut s'apparenter à une moyennisation du signal sur un voisinage glissant. En effet on a :

$$\begin{aligned}
 y(n) &= h_{DMA} * x(n) \\
 \Leftrightarrow y(n) &= \sum_{k=-\infty}^{+\infty} h_{DMA}(k)x(n-k) \\
 \Leftrightarrow y(n) &= \sum_{k=0}^{N-1} \frac{1}{N}x(n-k) \\
 \Leftrightarrow y(n) &= \frac{1}{N}(x(n) + x(n-1) + \dots + x(n-N+1))
 \end{aligned}$$

$$\Leftrightarrow y(n) = \frac{1}{N}x(n) + y(n-1) - \frac{1}{N}x(n-N)$$

La réponse impulsionnelle est non nulle sur un nombre fini de valeurs. C'est donc un filtre à réponse impulsionnelle finie (RIF). C'est un filtre à entrée bornée et sortie bornée, donc il est stable. D'autre part, le filtre ne dépend que du présent et du passé, donc il est causal.

2.2.2. Fonction de transfert

$$\text{On a } y(n) = \frac{1}{N}x(n) + y(n-1) - \frac{1}{N}x(n-N).$$

$$\text{Donc } Y(z) = \frac{1}{N}X(z) + z^{-1}Y(z) - \frac{1}{N}z^{-N}X(z)$$

$$\Leftrightarrow Y(z) - z^{-1}Y(z) = \frac{1}{N}X(z) - \frac{1}{N}z^{-N}X(z)$$

$$\Leftrightarrow (1 - z^{-1})Y(z) = \frac{1}{N}(1 - z^{-N})X(z)$$

$$H(z) = \frac{Y(z)}{X(z)} = \frac{\frac{1}{N}(1 - z^{-N})}{1 - z^{-1}}$$

La fonction de transfert du filtre est donc : $H(z) = \frac{1}{N} \frac{1 - z^{-N}}{1 - z^{-1}}$.

Le filtre admet un pôle en $z^{-1} = 1$ soit $z = 1$ et N zéros en $z^{-N} = 1$ soit $z = e^{\frac{2jk\pi}{N}}$ avec $k = 0, \dots, N-1$.

Pour $N = 13$, les pôles et les zéros sont représentés sur la **Figure 6**.

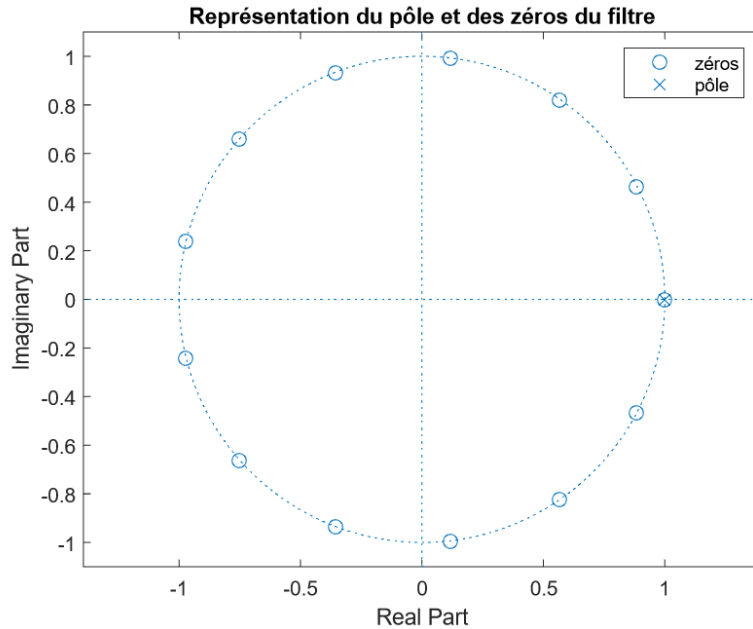


Figure 6 : Représentation du pôle en $z=1$ et des zéros en $z = e^{\frac{2jk\pi}{N}}$ du filtre

La réponse en fréquence du filtre est $H(f) = H(z) \big|_{z=e^{j2\pi\nu}}$, avec $\nu = \frac{f}{f_{ech}}$

$$\text{Donc, } H(f) = \frac{1}{N} \frac{1 - e^{-j2\pi N\nu}}{1 - e^{-j2\pi\nu}}.$$

$$\Leftrightarrow H(f) = \frac{1}{N} \frac{e^{-j\pi N\nu} e^{j\pi N\nu} - e^{-j\pi N\nu}}{e^{-j\pi\nu} e^{j\pi\nu} - e^{-j\pi\nu}}$$

$$\Leftrightarrow H(f) = \frac{e^{-j\pi(N-1)\nu} \sin(N\pi\nu)}{N \sin(\pi\nu)}$$

2.2.3. Phase et module de la fonction de transfert

2.2.3.1. Phase et retard de groupe

On sait que la phase du filtre est $\varphi_H(f) = \arg(H(f))$ donc $H(f) = |H(f)|e^{j\varphi_H(f)}$ avec $|H(f)|$ le module.

Par identification, on a donc $\varphi_H(f) = -\pi v(N-1)$. Comme la pulsation normalisée est $\omega = 2\pi \frac{f}{f_{ech}} = 2\pi v$, on a $\varphi_H(f) = \frac{1-N}{2} \omega$.

La phase de la réponse du filtre est linéaire, le retard de groupe est donc constant et égal à $\tau_G(\omega) = -\frac{\partial \varphi_H(\omega)}{\partial \omega} = \frac{N-1}{2}$. On peut observer ce retard de groupe en **Figure 7**.

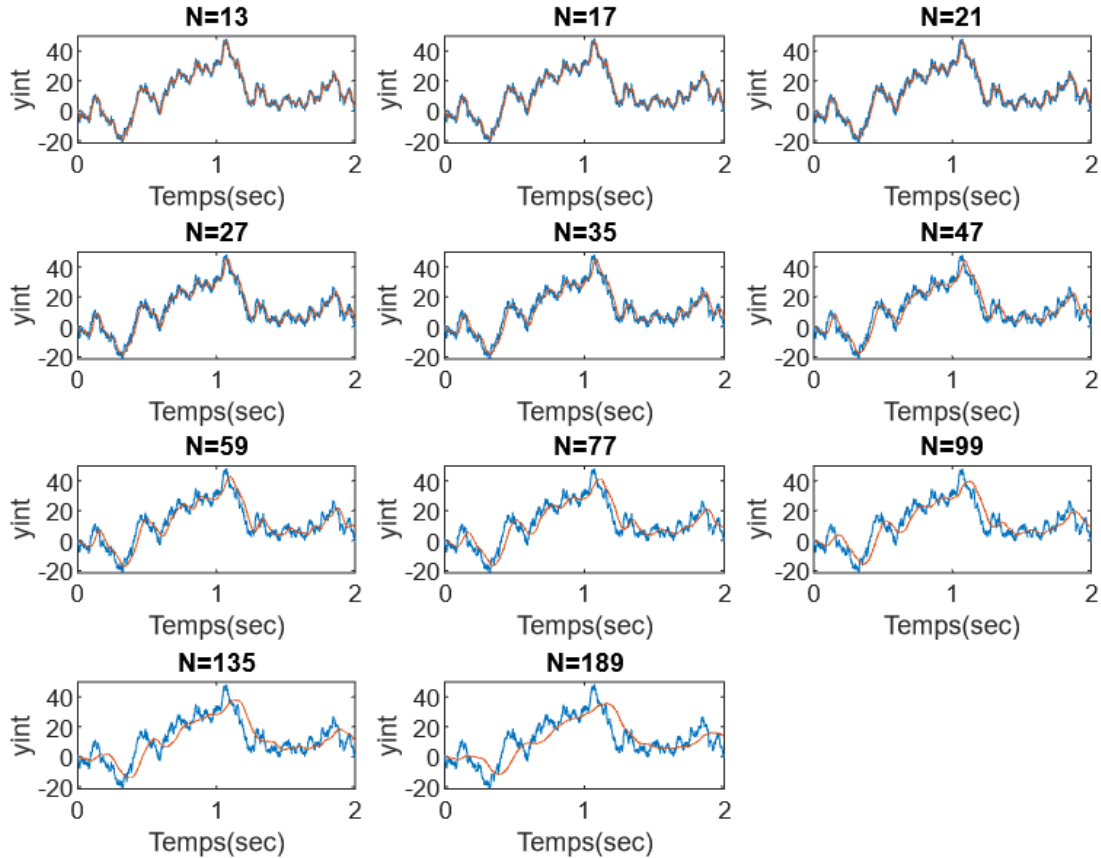


Figure 7 : Profil du signal en entrée et en sortie du filtre pour différents N

Nous remarquons sur la **Figure 7** un décalage entre le signal d'entrée et le signal filtré. Plus N est grand, plus ce décalage est important, ce qui correspond à la valeur du retard de groupe $\tau_G(\omega)$ trouvée plus haut.

Afin de corriger ce retard de groupe, il faut supprimer les $\frac{N-1}{2}$ premiers échantillons. Nous obtenons alors la **Figure 8**, qui représente les tendances globales.

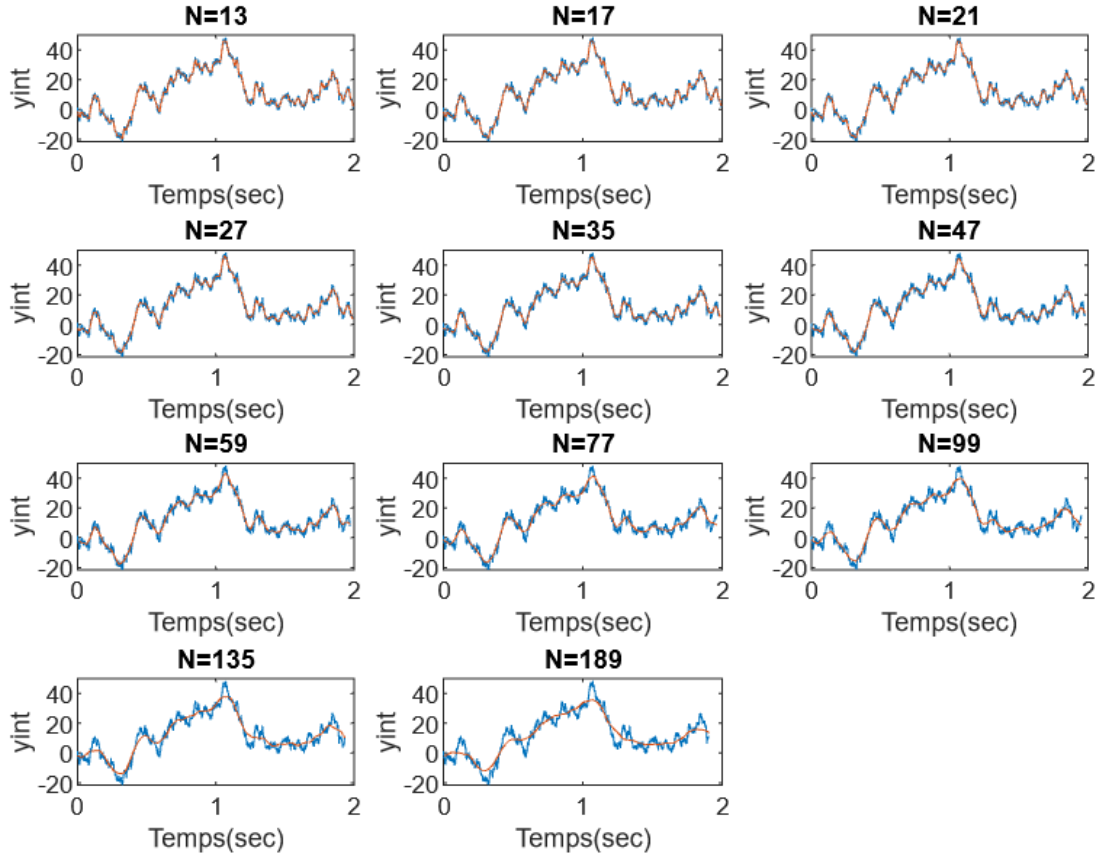


Figure 8 : Profil et tendance globale du signal pour différents N

On remarque que plus N est grand, plus le filtre “lisse” le signal.

2.2.3.2. Nature du filtre

On s'intéresse maintenant à la nature du filtre. Nous savons que la phase est $\varphi_H(f) = -\pi v(N - 1)$.

Le module du filtre est $|H(f)| = \left| \frac{e^{-j\pi(N-1)v}}{N} \frac{\sin(N\pi v)}{\sin(\pi v)} \right|$.

Donc, $|H(f)| = \frac{1}{N} \frac{\sin(N\pi v)}{\sin(\pi v)} |e^{-j\pi(N-1)v}| \Leftrightarrow |H(f)| = \frac{1}{N} \frac{\sin(N\pi v)}{\sin(\pi v)}$.

On a aussi :

- $|H(0)| = \frac{1}{N} \frac{N\pi v}{\pi v} = \frac{1}{N} N = 1$ car $\lim_{x \rightarrow 0^+} \sin(x) = x$
- $|H(\frac{f_{ech}}{2})| = \frac{1}{N} \frac{\sin(\pi N \frac{f_{ech}}{2f_{ech}})}{\sin(\pi \frac{f_{ech}}{2f_{ech}})} = \frac{1}{N} \frac{\sin(\frac{\pi N}{2})}{\sin(\frac{\pi}{2})} = \frac{1}{N} \sin(\frac{\pi}{2} N)$

Nous pouvons alors distinguer trois cas en fonction des valeurs de N :

- Si N est pair, c'est-à-dire, $N = 2k$ avec k entier naturel, $\sin(\frac{\pi}{2} N) = \sin(k\pi) = 0$.
Donc, $|H(\frac{f_{ech}}{2})| = 0$.
- Si N est impair,
 - Si $N = 4k + 1$ avec k entier naturel, $\sin(\frac{\pi}{2} N) = \sin(2k\pi + \frac{\pi}{2}) = \sin(\frac{\pi}{2}) = 1$.
Donc, $|H(\frac{f_{ech}}{2})| = \frac{1}{N}$.

- Si $N = 4k - 1$ avec k entier naturel, $\sin(\frac{\pi}{2}N) = \sin(2k\pi - \frac{\pi}{2}) = \sin(-\frac{\pi}{2}) = -1$. Donc, $|H(\frac{f_{ech}}{2})| = -\frac{1}{N}$.

Comme $|H(0)| = 1$, le filtre laisse passer les basses fréquences. Comme $|H(\frac{f_{ech}}{2})| < 1$ quelle que soit la valeur de N , le filtre atténue les hautes fréquences. Ce filtre est donc un filtre passe-bas.

2.2.3.3. Représentation graphique

La phase et le module de $H(f)$ (pour $N=13$) sont représentés en **Figure 9**.

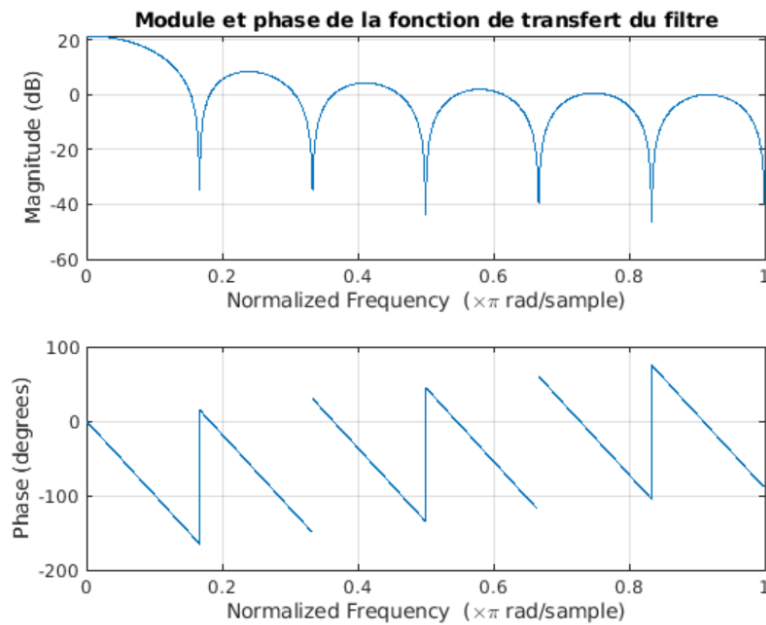


Figure 9 : Module et phase de $H(f)$

On observe sur la représentation du module que le filtre laisse passer les basses fréquences (proches de 0). Ceci confirme la nature passe-bas du filtre.

D'autre part, on remarque que sur la bande passante (environ $[0; 0,15]$) la phase est linéaire et décroissante, ce qui correspond à la formule trouvée plus haut.

2.2.4. Exposant de Hurst

Comme pour la DFA3, on a $F(n) \propto n^\alpha$ avec α l'exposant de Hurst. On peut alors représenter $\log(F(N))$ en fonction de $\log(N)$ (**Figure 10**).




Figure 10 : Pente de la représentation log-log

2.2.5. Test sur signaux synthétiques de régularité connue

Afin de vérifier l'exactitude de nos calculs, nous les répétons sur une cinquantaine de bruits blancs gaussiens centrés et une cinquantaine de bruits blancs de moyenne $\mu = 7$ et de variances $\sigma^2 = 9$ en recherchant $\alpha = 0,5$. On obtient alors une moyenne $\underline{\alpha} = 0,4915$ et une variance de $1,0 \cdot 10^{-3}$ pour les bruits blancs gaussiens centrés et une moyenne $\underline{\alpha} = 0,4886$ et une variance de $1,5 \cdot 10^{-3}$ pour les bruits blancs de moyenne non nulle. Dans les deux cas, la variance est très faible et la moyenne est proche de 0,5. Cela nous permet donc de valider le code et d'obtenir des résultats avec une faible variabilité.

3. Mise en oeuvre sur des signaux physiologiques

On se propose ici d'analyser des signaux réels, provenant d'électro-encéphalogrammes (EEG) en reprenant les 3 méthodes développées précédemment. Notre but est d'étudier la corrélation possible entre la profondeur d'encodage mémoriel et la régularité du signal. Plus généralement, nous allons essayer de voir la corrélation entre un état physiologique et un signal physiologique. La régularité du signal témoigne de sa cohérence structurelle, c'est-à-dire de la "mémoire" du processus et nous permet de discerner un bruit informe d'un processus cohérent. Nous disposons des signaux EEG de 7 sujets, relevés avec deux électrodes différents. L'expérience se divise en deux étapes représentant deux tâches de mémorisation différentes, la première formelle, la deuxième sémantique. On fait l'hypothèse H_0 suivante : "les deux phases font appel à deux niveaux de mémorisation distincts". Nous voulons donc étudier la séparabilité des phases.

Pour chaque combinaison (sujet, électrode, phase), nous étudions le coefficient de Hurst obtenu par la méthode DFA3 puis par la méthode DMA. Nous appliquons ensuite une analyse statistique ANOVA pour vérifier l'hypothèse. Plus la p-valeur obtenue est faible, plus il est possible de distinguer les deux phases.

Pour le premier électrode avec la méthode DFA3, nous obtenons :

	Sujet 1	Sujet 2	Sujet 3	Sujet 4	Sujet 5	Sujet 6	Sujet 7
--	---------	---------	---------	---------	---------	---------	---------

Phase 1	0,8648	1,0124	0,9383	0,8699	0,9863	0,8695	0,9134
Phase 2	0,8062	0,8113	0,8334	0,6988	0,7950	0,7537	0,7787

Dans ce cas, on obtient une p-valeur de 0,03%.

Pour le premier électrode avec la méthode DMA, nous obtenons :

	Sujet 1	Sujet 2	Sujet 3	Sujet 4	Sujet 5	Sujet 6	Sujet 7
Phase 1	0,9692	0,9717	0,8674	0,8914	1,0945	0,7835	0,8892
Phase 2	0,9119	0,8412	0,7573	0,7783	0,7680	0,6723	0,7777

Dans ce cas, on obtient une p-valeur de 1,25%.

Pour le deuxième électrode avec la méthode DFA3, nous obtenons :

	Sujet 1	Sujet 2	Sujet 3	Sujet 4	Sujet 5	Sujet 6	Sujet 7
Phase 1	0,9432	0,8435	0,8920	0,9313	1,0543	0,8465	0,8757
Phase 2	0,8918	0,7229	0,7475	0,8447	0,7938	0,7637	0,6987

Dans ce cas, on obtient une p-valeur de 0,46%.

Pour le deuxième électrode avec la méthode DMA, nous obtenons :

	Sujet 1	Sujet 2	Sujet 3	Sujet 4	Sujet 5	Sujet 6	Sujet 7
Phase 1	0,9153	0,7778	0,7100	0,9936	1,2304	0,8165	0,9888
Phase 2	0,8937	0,7161	0,5791	0,8666	0,8416	0,5967	0,8084

Dans ce cas, on obtient une p-valeur de 7,19%.

La p-valeur la plus faible est obtenue pour le premier électrode et avec la méthode DFA. Il semblerait donc que ce soit la configuration la plus appropriée pour étudier les deux niveaux de mémorisation. D'une certaine manière, c'est comme si le phénomène de mémorisation était mieux mis en exergue dans le signal par une régression d'ordre 3 que par un filtrage. Afin de vérifier cela, nous avons placé les valeurs des coefficients de Hurst sur les **Figures 11, 12, 13 et 14.**

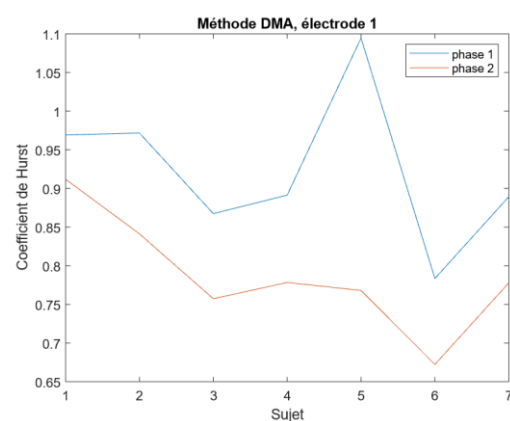



Figure 11 : Exposant de Hurst pour le premier électrode avec la DFA3




Figure 13 : Exposant de Hurst pour le deuxième électrode avec la DFA3

Figure 12 : Exposant de Hurst pour le premier électrode avec la DMA

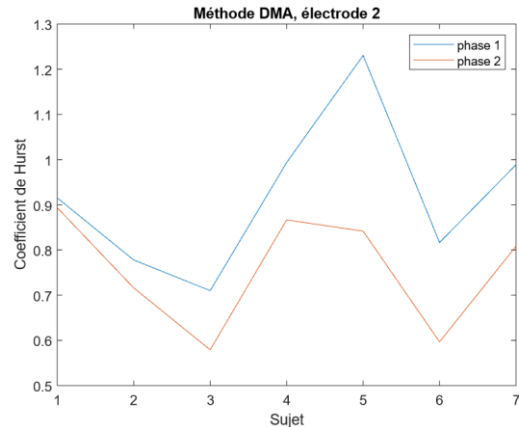


Figure 14 : Exposant de Hurst pour le deuxième électrode avec la DMA

On observe ici que la seule configuration permettant de tracer un seuil séparant la phase 1 de la phase 2 est la méthode DFA 3 pour le premier électrode. Cela signifie qu'il serait particulièrement simple d'automatiser la reconnaissance des phases et cela suggère qu'on arrive à déterminer un effet significatif sur l'ensemble des sujets. Pour les signaux biomédicaux, il est rare de déterminer des tendances remarquables de manière inter-individuelle. Autrement dit, la méthode DFA est plus propice à mesurer l'encodage que la méthode DMA car elle permet d'avoir des résultats qui s'affranchissent de la variabilité inter-individuelle (une discrimination claire quelque soit le sujet). Déterminer cette démarcation linéaire entre les 2 groupes permettrait de dire si un encodage est sémantique ou formel en fonction de s'il se trouve en dessous ou au-dessus de cette ligne. Ceci confirme l'analyse de la p-valeur et nous permet d'affirmer qu'il est plus pertinent d'appliquer la méthode DFA 3 au signal.

4. Gestion de projet

N'ayant pas accès à Matlab sur nos ordinateurs personnels, nous avons utilisé la version d'essai Matlab Online pour réaliser ce projet. Le tableau ci-dessous présente le temps passé par chacun de nous sur chaque tâche.

Tâche	Tom	Maika
Analyse fréquentielle d'un signal	3h de TP + 2h	3h de TP + 2h
Analyse de la régularité : DFA3	Absence justifiée + 3h	3h de TP + 8h
Analyse de la régularité : DMA	Absence justifiée + 6h	3h de TP + 7h
Mise en oeuvre sur des	3h de TP + 3h	3h de TP + 2h

signaux physiologiques		
Rapport (introduction, conclusion, mise en page)	6h	2h

Figure 15 : Tableau de gestion de projet

Conclusion

L'expérience menée sur l'encodage mémoriel avait pour objectif de mesurer les différences des régularités des signaux EEG des sujets entre deux phases d'encodage d'une liste d'une vingtaine de mots : la première phase faisant appel à une mémorisation **formelle** lorsque la deuxième fait intervenir la mémorisation **sémantique**. On s'aperçoit que, pour l'ensemble des sujets, le critère de Hurst est inférieur à 1.5, et se diminue entre la phase 1 et la phase 2. Pour certains sujets, α se rapproche de 0.5 pour la phase 2. On sait qu'en phase d'apprentissage, la profondeur mémorielle dépend du mode de mémoire sollicitée. Ainsi, la mémoire sémantique est plus profonde que la mémoire formelle. Nos résultats nous montrent que la phase formelle a un α plus élevé que la phase sémantique. On peut donc dire que **plus l'encodage est profond plus la régularité du signal est faible**.

Ce TP nous aura permis d'appréhender le traitement numérique d'un signal physiologique. Non seulement en nous permettant de manipuler les méthodes d'analyses temps-fréquence des signaux mais aussi en étudiant la régularité d'un signal selon deux méthodes : Detrending Fluctuation Analysis d'ordre 3 (DFA3) et Detrending Moving Average (DMA). Dans un cas, il aura fallu commencer par analyser les tendances locales sur un nombre de segments défini pour ensuite les concaténer en une tendance globale, tandis que dans l'autre un filtre passe-bas est appliqué au signal pour en déduire une tendance.

Appliquer ces méthodes nous met dans la situation d'un ingénieur cognitif : mettre en pratique des outils d'analyse, comprendre le sujet abordé et déduire une méthodologie scientifique. Enfin, ce TP nous a permis de mieux maîtriser l'outil Matlab.

Bibliographie

Martin, C., Hourlier, S. & Cegarra, J. (2013). La charge mentale de travail : un concept qui reste indispensable, l'exemple de l'aéronautique. *Le travail humain*, vol. 76(4), 285-308.
<https://doi-org.ezproxy.u-paris.fr/10.3917/th.764.0285>